Archives : du papier au texte

La numérisation des archives d'une entreprise ne se limite pas à produire des images : encore faut-il pouvoir y retrouver une information. Reconnaître le texte d'une page scannée exige d'abord de la redresser, puis de distinguer le papier de l'encre, enfin de lire chaque ligne. Les caractères accentués, les ligatures et les chiffres mettent les moteurs à l'épreuve ; une virgule mal lue dans un montant suffit à fausser un total. C'est pourquoi chaque mot reçoit une note de confiance, qui signale à l'utilisateur les passages à vérifier. Un œil exercé repère vite ces hésitations : « 1 » pris pour « l », « 0 » pour « O », ou « é » privé de son accent.